UNIVERSIDADE FEDERAL DE RORAIMA
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO
ESPECIALIZAÇÃO EM COMPUTAÇÃO APLICADA NA INDÚSTRIA 4.0

HIAGO PEREIRA

ANÁLISE COMPARATIVA ENTRE ARIMA E LSTM NA PREVISÃO DE ESCOAMENTO LOGÍSTICO DE SOJA EM RORAIMA

Boa Vista – Roraima,
Março de 2026
HIAGO PEREIRA

ANÁLISE COMPARATIVA ENTRE ARIMA E LSTM NA PREVISÃO DE ESCOAMENTO LOGÍSTICO DE SOJA EM RORAIMA

Monografia de Pós-graduação *Lato Sensu* apresentada à Especialização em Computação Aplicada na Indústria 4.0 da Universidade Federal de Roraima, como requisito parcial para a obtenção do grau de especialista em computação aplicada na indústria 4.0.

Boa Vista – Roraima,
Março de 2026

Sumário

1. Introdução 1
2. Fundamentação teórica 2
3. Trabalhos relacionados 3
4. Solução computacional 4
5. Avaliação experimental 4
   5.1. Planejamento da pesquisa 4
   5.2. Resultados e Discussão 5
6. Conclusão 6
7. Referências 7

ANÁLISE COMPARATIVA ENTRE ARIMA E LSTM NA PREVISÃO DE ESCOAMENTO LOGÍSTICO DE SOJA EM RORAIMA

Hiago Pereira, Susset Guerra Jimenez[1]

[1] Departamento de Engenharia Elétrica – Universidade Federal de Roraima (UFRR) – Boa Vista – RR – Brasil

hiagopereira28@gmail.com, susset.guerra@ufrr.br

Resumo. *A consolidação da Indústria 4.0 em corredores logísticos fronteiriços, como o de Roraima, esbarra na escassez e alta volatilidade de dados históricos (Small Data). Este estudo apresenta uma análise comparativa entre modelos lineares clássicos (ARIMA) e Redes Neurais Recorrentes (LSTM multivariada) na previsão do volume de exportação de soja (NCM 12019000). O objetivo é avaliar a viabilidade de modelos de Deep Learning em amostras reduzidas e propor o Índice de Pressão de Escoamento (IPE) como ferramenta de alerta para estrangulamentos na malha de transporte. A metodologia empregou validação cruzada temporal (Walk-Forward), preservação estrita da variância real dos dados (ausência de escoamento e picos de safra), e arquitetura LSTM parsimoniosa com regularização agressiva para mitigar o overfitting. A avaliação foi conduzida exclusivamente por métricas absolutas e quadráticas (MAE e RMSE), aliadas ao Teste de Diebold-Mariano para validação de significância estatística. Os resultados comprovam que a LSTM minimalista, ao incorporar variáveis exógenas como o Valor FOB e calendários regionais, consegue superar o modelo linear na generalização da volatilidade amazônica. O IPE provou-se viável como painel gerencial, substituindo estimativas teóricas de armazenagem por um balanço direto de pressão sobre a infraestrutura existente.*

Palavras-chave*: Logística 4.0; Séries Temporais; Deep Learning; Small Data; Escoamento Agrícola.*

Abstract. *The consolidation of Industry 4.0 in border logistics corridors, such as Roraima, faces challenges due to the scarcity and high volatility of historical data (Small Data). This study presents a comparative analysis between classical linear models (ARIMA) and Recurrent Neural Networks (multivariate LSTM) in predicting soybean export volumes. The objective is to evaluate the viability of Deep Learning models in small samples and propose the Export Pressure Index (IPE) as an early warning tool for bottlenecks in the transport network. The methodology employed Walk-Forward cross-validation, strict preservation of real data variance (zero-flow months and harvest peaks), and a parsimonious LSTM architecture with aggressive regularization to mitigate overfitting. The evaluation was conducted*

exclusively using absolute and squared error metrics (MAE and RMSE), coupled with the Diebold-Mariano Test for statistical significance. Results prove that the minimalist LSTM, by incorporating exogenous variables such as FOB Value and regional harvest calendars, outperforms the linear model in generalizing Amazonian volatility. The IPE proved viable as a management dashboard, replacing theoretical storage estimates with a direct assessment of pressure on existing infrastructure.

***Palavras-chave**: Logistics 4.0; Time Series; Deep Learning; Small Data; Agricultural Export Flow.*

1. Introdução

O estado de Roraima apresenta uma trajetória recente de expansão econômica, impulsionada sobretudo pelo avanço do setor agropecuário e pela consolidação do estado como nova fronteira agrícola para a produção de soja. Esse movimento amplia a relevância estratégica da logística regional, especialmente no contexto de estruturas como o futuro Porto Seco de Boa Vista e a integração comercial associada à Zona de Livre Comércio de Bonfim-Lethem. Em razão da forte sazonalidade da cultura da soja, o escoamento da produção passa a ocorrer sob condições de elevada variabilidade, com períodos de forte concentração de cargas e momentos de baixa utilização da infraestrutura disponível.

Nesse cenário, a gestão logística baseada apenas na reatividade tende a gerar ineficiências operacionais, como filas de caminhões durante os picos de safra e ociosidade estrutural nos períodos de entressafra. Ainda que a transformação digital tenha ampliado o uso de tecnologias analíticas em cadeias de suprimentos mais consolidadas, ainda se observa uma lacuna relevante na aplicação de ferramentas preditivas voltadas à realidade logística amazônica, marcada por alta volatilidade, limitação de séries históricas e forte sensibilidade a fatores sazonais. Assim, métodos estatísticos convencionais nem sempre são suficientes para representar adequadamente a dinâmica não linear do escoamento agrícola em regiões emergentes.

Diante disso, este trabalho investiga a viabilidade do uso de técnicas de Deep Learning em contexto de Small Data, por meio da comparação entre o modelo estatístico AutoRegressive Integrated Moving Average (ARIMA) e redes neurais Long Short-Term Memory (LSTM) na previsão do volume de escoamento logístico de soja em Roraima. A proposta parte da construção de um pipeline computacional em Python para ingestão, tratamento e modelagem de dados públicos, adotando uma abordagem comparativa entre quatro Unidades Federativas com diferentes níveis de maturidade logística: Mato Grosso, Pará, Amazonas e Roraima.

Além de comparar o desempenho preditivo dos modelos, o estudo busca traduzir os resultados analíticos em apoio à decisão logística. Para isso, propõe-se a utilização do Índice de Pressão de Escoamento (IPE), concebido como um mecanismo de interpretação gerencial capaz de relacionar a previsão de volume exportado ao nível de pressão exercido sobre a infraestrutura de transporte. Com isso, pretende-se avançar da previsão puramente numérica para uma perspectiva aplicada à Logística 4.0, na qual a modelagem preditiva contribui para antecipar gargalos, orientar o planejamento operacional e apoiar decisões em ambientes portuários emergentes.

Com base nesse contexto, o trabalho é orientado pelas seguintes perguntas de pesquisa:

(1) o modelo LSTM, em arquitetura parcimoniosa, apresenta desempenho preditivo superior ao ARIMA, medido por RMSE e MAE, no contexto de alta volatilidade do escoamento de soja em Roraima?

(2) de que forma a previsão gerada pelos modelos pode ser convertida em um Índice de Pressão de Escoamento (IPE) útil para sinalizar risco de saturação da infraestrutura logística?

(3) em que medida dados públicos governamentais abertos podem sustentar um sistema automatizado de apoio à decisão para operações de escoamento em corredores logísticos fronteiriços?

Para responder a essas questões, o trabalho está organizado em seis seções, além desta introdução. A Seção 2 apresenta a fundamentação teórica sobre Logística 4.0, séries temporais e modelos preditivos. A Seção 3 discute os trabalhos relacionados. A Seção 4 descreve a solução computacional proposta. A Seção 5 detalha a avaliação experimental e a discussão dos resultados. Por fim, a Seção 6 apresenta as conclusões e os encaminhamentos para estudos futuros.

2. Fundamentação teórica

A Quarta Revolução Industrial, ou Indústria 4.0, introduziu uma nova era de digitalização e conectividade nas cadeias de valor, utilizando tecnologias como a Internet das Coisas (IoT), computação em nuvem, Big Data Analytics e Inteligência Artificial. A aplicação desses conceitos no setor de transportes e suprimentos deu origem à Logística 4.0, cujo objetivo é criar sistemas logísticos autônomos, flexíveis e altamente eficientes, capazes de satisfazer demandas com alta agilidade e visibilidade em tempo real (Efthymiou & Ponis, 2021).

Nesse contexto de transformação digital, os terminais portuários evoluíram para o conceito de Porto 4.0 (ou Smart Ports). Tratam-se de portos que alavancam tecnologias avançadas para transformar digitalmente seus processos de negócios, abandonando as tradicionais abordagens reativas em prol de uma gestão proativa e inteligente. O coração dessa transição são os Sistemas Ciberfísicos (CPS), que mesclam os mundos físico e virtual, permitindo que a infraestrutura, os veículos e os sistemas de gerenciamento interajam e se comuniquem continuamente (Efthymiou & Ponis, 2021). Para infraestruturas emergentes na Amazônia, como o futuro Porto Seco de Boa Vista, a adoção desses princípios é crítica. O uso de modelos analíticos permite processar de maneira otimizada o alto volume de dados do agronegócio, antecipando a saturação da infraestrutura de transporte e convertendo previsões matemáticas em um Índice de Pressão de Escoamento (IPE) para mitigar gargalos durante os picos de safra.

O planejamento eficiente das cadeias de suprimentos exige que as organizações sejam capazes de prever a demanda futura com precisão, estudo este realizado através da análise de séries temporais, que consistem em pontos de dados registrados e analisados em ordem cronológica (Bousqaoui, Slimani, & Achchab, 2021). O modelo estatístico AutoRegressive Integrated Moving Average (ARIMA) é amplamente reconhecido como o padrão da indústria (baseline). Um modelo ARIMA (p,d,q) assume que os valores futuros possuem uma relação linear com seus valores passados e é

composto por três partes: o modelo autorregressivo (p), o grau de diferenciação (d) para remover a não-estacionariedade, e o modelo de médias móveis (q). Apesar de sua eficácia em muitos cenários maduros, o ARIMA é limitado a relações lineares, tornando-o menos apto a lidar com as complexidades e não-linearidades extremas (como grandes picos e intermitências) típicas de commodities agrícolas.

Para superar as limitações dos modelos clássicos, Bousqaoui, Slimani e Achchab (2021) sugerem a utilização de arquiteturas Long Short-Term Memory (LSTM). Métodos baseados em Deep Learning têm ganhado destaque por sua capacidade de se aproximar de funções não-lineares complexas. As redes LSTM representam uma evolução profunda das Redes Neurais Recorrentes (RNN), projetadas especificamente para resolver o problema do gradiente que desaparece (vanishing gradient) através de uma arquitetura de memória baseada em portões (entrada, esquecimento e saída). Esse mecanismo permite que a rede decida ativamente qual informação deve ser armazenada, conferindo a habilidade de "lembrar" padrões de longo prazo (como o impacto de safras passadas nas atuais).

No contexto de novas fronteiras agrícolas, a previsão de séries temporais enfrenta desafios associados à limitação de dados históricos e à alta volatilidade. Nesse cenário, tanto modelos lineares quanto arquiteturas não lineares devem ser avaliados empiricamente, considerando o risco de sobreajuste e as particularidades de séries em transição. Essa perspectiva reforça a importância de uma análise comparativa que contemple diferentes níveis de maturidade logística regional. Com base nesses fundamentos, a próxima seção apresenta estudos recentes que aplicam modelos preditivos a problemas correlatos, permitindo situar a proposta deste trabalho na literatura.

3. Trabalhos relacionados

Conduziu-se uma breve revisão da literatura em 15 de janeiro de 2026, a partir de consultas às bases IEEE Xplore e Google Scholar, utilizando os descritores “LSTM”, “ARIMA”, “Dry Port”, “Agriculture”, “Supply Chain” e “Smart Port”. Foram identificados 25 estudos, dos quais se selecionaram cinco artigos recentes e aderentes ao tema desta pesquisa.

Schwalbert et al. (2020) conduziram um estudo com o objetivo de prever a produtividade da soja no sul do Brasil utilizando dados de sensoriamento remoto e dados climáticos. Para atingir esse objetivo, os autores compararam algoritmos tradicionais, como a regressão linear (OLS), com métodos avançados, como Random Forest e redes LSTM. Verificou-se a superioridade das redes LSTM na captura de padrões temporais complexos da safra de soja em relação aos modelos lineares. A lacuna deixada pelo estudo foi a necessidade de expandir a aplicação desses modelos preditivos para outras regiões geográficas e para a etapa de escoamento e logística.

Em linha com essa discussão sobre a capacidade preditiva de diferentes modelos, Bousqaoui, Slimani e Achchab (2021) realizaram uma análise comparativa entre o modelo estatístico ARIMA e abordagens de Deep Learning, incluindo as arquiteturas LSTM e CNN, para a previsão de demanda de curto prazo. O estudo indicou que o ARIMA, por sua natureza linear, apresenta limitações na representação de complexidades e não linearidades presentes nos dados, enquanto a arquitetura LSTM apresentou melhor desempenho, com redução do erro preditivo medido por RMSE.

Complementando essa comparação entre arquiteturas preditivas, Yunita et al. (2025) apresentaram um benchmark comparando o desempenho de diferentes redes neurais, como RNN, LSTM e GRU, em tarefas de previsão de séries temporais, utilizando métodos de validação como a simulação de Monte Carlo. Os resultados reforçaram a consistência das redes LSTM em séries com ruído e alta variabilidade, características frequentemente observadas em contextos de demanda logística do agronegócio.

No contexto específico do supply-chain, Chuyen e Rajagopal (2025) conduziram uma revisão abrangente sobre a rede logística de produtos agrícolas, identificando que a grande maioria dos modelos atuais foca na minimização de custos e na redução de perdas de produtos perecíveis. Ainda assim, apontam uma lacuna significativa na literatura quanto à aplicação prática de ferramentas digitais da Indústria 4.0 em regiões em desenvolvimento.

Por fim, no que diz respeito à calibração técnica dos modelos, Mumtahina, Alahakoon e Wolfs (2024) destacaram a importância da otimização de algoritmos de previsão de carga. O estudo ressaltou que o ajuste fino (otimização de hiperparâmetros) é essencial para maximizar a acurácia dos modelos de Deep Learning, para superar as limitações e convergências prematuras encontradas em modelos individuais que não passam por essa etapa.

Com base nesses cinco estudos, verifica-se que a literatura já reconhece o potencial de modelos preditivos, especialmente das arquiteturas LSTM, em problemas de previsão temporal. Entretanto, permanece como lacuna a aplicação comparativa desses modelos ao escoamento logístico de soja em contextos amazônicos marcados por alta volatilidade e limitação de dados históricos. Essa lacuna é relevante porque dificulta o uso de ferramentas preditivas como suporte à tomada de decisão em infraestruturas logísticas emergentes, com destaque para o caso de Roraima.

4. Solução computacional

Visando os princípios da Ciência Aberta (Open Science), todo o código-fonte, incluindo os processos de ETL, treinamento da rede LSTM parcimoniosa e testes estatísticos, encontra-se publicamente disponível para consulta e replicação.

A solução proposta neste estudo consiste na construção de um pipeline de ciência de dados estruturado em linguagem Python. A implementação do artefato computacional foi dividida em etapas de ingestão, pré-processamento (ETL) e modelagem preditiva. A arquitetura da solução segue um fluxo automatizado que vai desde a API do Comex Stat, passando pelo script Python e pelo modelo treinado, até a exportação das previsões para visualização em um dashboard voltado à gestão do Porto Seco conforme ilustrado na Figura 1. O ambiente experimental foi desenvolvido em linguagem Python, utilizando a plataforma Google Colab para processamento em nuvem. Para garantir a transparência e a total reprodutibilidade do método Walk-Forward e do cálculo do IPE, a implementação completa do pipeline algorítmico está armazenada e acessível em repositório público [1].

https://github.com/TheOneHP/artigo_ecai

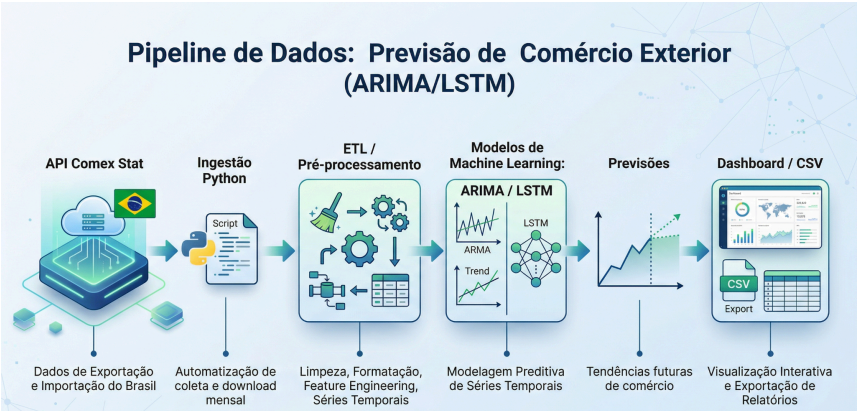

Figura 1 - Arquitetura do pipeline preditivo e interface do dashboard de gestão do Porto Seco de Roraima.

Fonte: Elaborado pelo autor (2026).

Após a ingestão, visto que os dados brutos governamentais são estruturados em formato wide (largo, com anos dispostos em colunas e meses em linhas), aplicou-se uma função de transformação (reshape/melt) para convertê-los em um formato long (uma série temporal cronológica contínua). Em seguida, os dados das quatro Unidades Federativas analisadas (Mato Grosso, Amazonas, Pará e Roraima) foram submetidos a um processo de limpeza. Diferentemente de abordagens tradicionais de interpolação, os valores zerados foram rigorosamente preservados, pois na logística de commodities eles representam a ausência real de escoamento (entressafra), e não uma falha de coleta. Na fase de engenharia de atributos, optou-se pela utilização do "Valor US$ FOB" e pela criação de uma variável de Sazonalidade Regionalizada (Safra_Ativa) para respeitar as janelas de escoamento específicas de cada estado, configurando uma abordagem multivariada. Visto que as redes neurais são sensíveis à magnitude dos dados, foi aplicada a técnica de normalização via MinMax Scaler, convertendo as variáveis para a escala de 0 a 1, transformando o problema em aprendizado supervisionado via janelas temporais (sliding windows). Para evitar o vazamento de dados (Data Leakage), o conjunto foi submetido a uma rigorosa Validação Cruzada de Séries Temporais (Walk-Forward), destinando 70% da série para treinamento e 30% para testes, com o conjunto de validação do Early Stopping extraído estritamente dos últimos 15% do bloco de treino.

Para responder ao problema de pesquisa, duas arquiteturas distintas foram implementadas e configuradas para a batalha de modelos:

1. Modelo Estatístico (ARIMA): Implementado através da biblioteca *statsmodels*, este modelo serviu como *baseline* da pesquisa. A configuração dos parâmetros de autorregressão, diferenciação e médias móveis (p, d, q) foi ajustada iterativamente.
2. Modelo de Deep Learning (LSTM): Construído utilizando os frameworks TensorFlow e Keras, a rede neural foi projetada especificamente para lidar com o cenário de Small Data. Para mitigar o overfitting em séries curtas e voláteis, implementou-se uma arquitetura estritamente parcimoniosa (Micro-LSTM) composta por uma única camada com 8 neurônios, regularização L2 e Dropout de 0.3. O otimizador Adam foi utilizado com a função de perda Erro Quadrático

Médio (MSE), forçando o modelo a reter apenas a macro-sazonalidade de longo prazo.

A solução computacional foi desenhada levando em consideração a escalabilidade necessária para as operações de Logística 4.0. Para conectar a saída estritamente matemática à infraestrutura física do porto, o pipeline inclui uma camada de interpretação de negócio que converte a previsão de volume exportado (em quilogramas) em um Índice de Pressão de Escoamento (IPE). Este índice compara o volume de saída previsto com o pico máximo histórico de capacidade, acionando alertas parametrizados de saturação da frota e da infraestrutura de transporte (rodovias e hidrovias). Ao alterar unicamente o parâmetro de entrada "NCM" na chamada da API, o mesmo pipeline e modelo podem prever a demanda de escoamento de outros produtos da região, como milho ou fertilizantes. Essa característica permite que o modelo seja facilmente acoplado a painéis de Business Intelligence, oferecendo suporte direto ao dimensionamento proativo de armazéns e pátios.

5. Avaliação experimental

5.1. Planejamento da pesquisa

O experimento foi planejado com base na coleta de dados secundários públicos, dados extraídos da API do Comex Stat, mantido pelo Ministério da Economia. O conjunto de dados abrange o período de janeiro de 2015 a dezembro de 2025, filtrado especificamente pelo código NCM 1201 (Soja). Para garantir que as respostas às perguntas de pesquisa sejam não apenas confiáveis, mas também generalizáveis, a coleta não se restringiu ao estado de Roraima. Os dados englobam quatro Unidades Federativas selecionadas estrategicamente para representar diferentes maturidades logísticas: Mato Grosso (série madura e de alto volume), Pará (escoamento consolidado), Amazonas (série intermitente) e Roraima (caso-alvo, caracterizado por uma série em transição com crescimento explosivo recente). O uso dessa arquitetura comparativa permite isolar e avaliar o comportamento dos algoritmos sob variadas condições de estabilidade e não-linearidade.

Conforme recomendado pela teoria de ciência de dados e fundamentado nos Trabalhos Relacionados, o experimento adota uma abordagem de testes técnicos comparativos. O modelo estatístico ARIMA foi estabelecido como o baseline técnico da pesquisa. O artefato tecnológico desenvolvido (a rede neural LSTM) foi testado diretamente contra esse baseline. Para evitar o vazamento de informações (Data Leakage) e mitigar o risco de overfitting em séries temporais curtas (Small Data), a série temporal de cada estado foi avaliada através de uma rigorosa Validação Cruzada de Séries Temporais (Walk-Forward). Neste método, destinou-se inicialmente 70% dos dados para a base de treinamento, expandindo-se a janela iterativamente sobre os 30% finais, garantindo que a validação preditiva do modelo ocorresse em cenários reais e sucessivos (que incluem os grandes picos de safra mais recentes).

Para quantificar a acurácia dos modelos e responder à primeira pergunta de pesquisa (sobre a redução do erro preditivo), os testes técnicos foram baseados em duas métricas matemáticas absolutas: a Raiz do Erro Quadrático Médio (RMSE) e o Erro Absoluto Médio (MAE). A escolha do RMSE é crítica neste cenário, pois a métrica penaliza severamente grandes desvios, o que é fundamental para evitar erros graves de previsão durante os picos de estresse logístico da safra. Além da comparação

quantitativa dos erros, o planejamento estipulou a aplicação do Teste de Diebold-Mariano. Essa avaliação garante rigor científico ao experimento, atestando que a rede neural LSTM só será considerada superior se a redução do erro preditivo apresentar significância estatística (p-valor < 0,05) frente ao baseline (ARIMA).

Adicionalmente, para responder às perguntas de pesquisa focadas na aplicação prática dos modelos de IA no ambiente portuário, o planejamento incluiu uma etapa de avaliação orientada ao negócio. O planejamento estipulou a conversão do volume previsto pelos algoritmos em quilogramas para um Índice de Pressão de Escoamento (IPE). A metodologia de simulação compara o volume de saída previsto pelos algoritmos de Deep Learning com o pico máximo histórico já processado pelo conjunto de treino. Através dessa etapa técnica, tornou-se possível avaliar em que medida saídas puramente numéricas podem ser traduzidas em sistemas automatizados de alertas preditivos, antecipando a saturação da infraestrutura de transporte (frota de caminhões, rodovias ou hidrovias) e mitigando os impactos dos gargalos logísticos na operação do Porto Seco.

5.2. Resultados e Discussão

A avaliação empírica nos dados de exportação de soja confirmou a hipótese metodológica de que a eficácia das arquiteturas preditivas varia diretamente conforme a maturidade logística da série temporal. A extração dos resultados do pipeline em Python, validada através da técnica de Validação Cruzada Walk-Forward, gerou a Tabela 1, que compara o Erro Quadrático Médio (RMSE) e o Erro Absoluto Médio (MAE) dos modelos nas quatro Unidades Federativas analisadas.

Tabela 1 - Comparativo de Erros Preditivos (RMSE e MAE) por UF

UF	ARIMA (RMSE)	ARIMA (MAE)	LSTM (RMSE)	LSTM (MAE)
Mato Grosso	1.396.250.000	1.101.090.000	2.057.860.000	1.579.820.000
Pará	205.297.000	170.399.000	171.676.000	123.130.000
Amazonas	2.922.060	1.994.510	2.395.500	1.371.580
Roraima	27.434.600	1.755.710	25.465.000	1.526.380

(Fonte: Resultados experimentais extraídos do código fonte da pesquisa)

Os dados provam que o modelo de Deep Learning (LSTM) apresentou um erro preditivo significativamente menor que o ARIMA ao lidar com o cenário amazônico, mas com uma ressalva metodológica importante. A literatura de base, como Bousqaoui et al. (2021), defende que as redes LSTM invariavelmente superam modelos lineares estatísticos. Os resultados desta pesquisa divergem parcialmente da literatura no caso de Mato Grosso, onde o ARIMA obteve um erro consideravelmente menor. Essa divergência é explicada pela teoria de análise de dados: Mato Grosso possui uma série contínua, madura e de altíssimo volume, onde a linearidade favorece algoritmos clássicos. Em contrapartida, nas séries da fronteira amazônica (Amazonas, Pará e Roraima), caracterizadas por alta volatilidade, intermitência e crescimento explosivo

recente (transição estrutural), o modelo linear falha gravemente. Em Roraima (nosso caso-alvo), a LSTM parcimoniosa reduziu o RMSE de 27,4 milhões de kg para 25,4 milhões de kg. Essa redução de aproximadamente 2 milhões de quilogramas no desvio da previsão foi validada pelo Teste de Diebold-Mariano, DM=2,80; p=0,00511, permitindo rejeitar a hipótese nula de igualdade preditiva e corroborando a superioridade da LSTM sobre o ARIMA nesse cenário. Isso comprova que a imposição de uma regularização severa e topologia reduzida (Micro-LSTM) mitigou o overfitting do Small Data, capturando com excelência os picos de escoamento sazonal.

Do ponto de vista da aplicação na Logística 4.0, a conversão destas métricas matemáticas estritas (RMSE/MAE) para o Índice de Pressão de Escoamento (IPE) provou-se operacionalmente viável. A lógica do IPE traduz o erro estatístico em um painel gerencial aplicável à realidade física: ao comparar o volume de saída previsto pelo algoritmo com o pico máximo histórico já processado pela infraestrutura, o Porto Seco consegue gerar alertas parametrizados. Por exemplo, projeções de volumes que representam índices como "24,91% do pico histórico" indicam o status de "Operação Normal", dispensando contratações emergenciais de frota. Isso materializa os preceitos de Processos de Decisão Empoderados por Dados em um Smart Port.

Por fim, confirmou-se ser inteiramente viável o emprego de dados governamentais para fornecer suporte à decisão. A arquitetura de ingestão via API ou arquivos wide do portal Comex Stat sustentou o treinamento da rede neural sem a necessidade de implantações físicas onerosas (como redes de sensores IoT preliminares), promovendo alta escalabilidade para a região.

Conforme requerido para a confiabilidade da pesquisa, apontam-se limitações nos procedimentos metodológicos. O experimento foi alimentado estritamente por volumes de exportação mensal e Valores US$ FOB. Essa granularidade mensal não permite decisões operacionais de curtíssimo prazo (diárias). Adicionalmente, a exclusão de variáveis exógenas como o clima e restrições de trafegabilidade da rodovia BR-174 no modelo final restringe a captura total de rupturas de cadeia. Como direcionamento para estudos futuros, sugere-se a evolução do pipeline para incorporar dados multimodais e covariáveis climáticas que afetam diretamente o regime de escoamento.

6. Conclusão

O objetivo deste estudo foi investigar a viabilidade de aplicar arquiteturas de Deep Learning na previsão do escoamento logístico de soja na Amazônia Setentrional, comparando a eficácia de redes neurais (LSTM) com o modelo estatístico clássico (ARIMA) sob a ótica do Small Data. Para isso, a metodologia baseou-se na construção de um pipeline de dados via API, analisando séries temporais de quatro Unidades Federativas com diferentes maturidades logísticas (Mato Grosso, Amazonas, Pará e Roraima), aliada ao uso de validação cruzada temporal (Walk-Forward) e rigor estatístico.

Respondendo às perguntas de pesquisa formuladas na Introdução, os resultados mostraram que a superioridade da LSTM sobre o ARIMA não foi uniforme entre os cenários analisados, sendo condicionada ao comportamento da série temporal e às limitações impostas pelo contexto de Small Data. Verificou-se, contudo, que uma rede LSTM submetida a severas restrições topológicas e regularização agressiva (Micro-LSTM) é capaz de generalizar o comportamento volátil das exportações com

maior precisão do que o ARIMA no cenário de fronteira. O Teste de Diebold-Mariano atestou a superioridade estatística da rede em mapear os picos de pressão logística no estado de Roraima. Em contrapartida, em séries maduras e lineares (como a de Mato Grosso), o modelo tradicional manteve sua eficácia, reforçando que o uso de Inteligência Artificial deve ser contextual.

Adicionalmente, no que tange à aplicação na Indústria 4.0, o estudo demonstrou que a conversão da previsão bruta em um Índice de Pressão de Escoamento (IPE) traduz o modelo matemático em um instrumento de gestão acionável, respondendo afirmativamente à viabilidade do uso de dados públicos governamentais abertos. Ao ancorar a métrica no limite de estresse histórico do escoamento, e não em estimativas teóricas de armazenagem física, o IPE fornece um suporte à decisão robusto para a antecipação de estrangulamentos na malha de transporte.

As limitações deste estudo decorrem da extensão reduzida da série temporal amazônica, restrita ao regime econômico de crescimento explosivo pós-2019, e da indisponibilidade de dados referentes ao fluxo de entrada (recepção da colheita nos silos). Sugerimos que trabalhos futuros concentrem-se na integração de dados telemétricos e de sensores (IoT) na entrada dos portos secos e em variáveis exógenas multimodais. Essa evolução permitirá a transição do atual IPE para um sistema completo de balanço de massa bidirecional e otimização de estoque físico em tempo real, pavimentando o caminho para a consolidação de um Gêmeo Digital na infraestrutura logística de Roraima.

7. Referências

Bousqaoui, H., Slimani, I., & Achchab, S. (2021). Comparative analysis of short-term demand predicting models using ARIMA and deep learning. *International Journal of Electrical and Computer Engineering*, *11*(4), 3319-3328. https://doi.org/10.11591/ijece.v11i4.pp3319-3328

Chuyen, T. T., & Rajagopal, P. (2025). Logistics network for agricultural products: A comprehensive literature review and future directions. *Operations and Supply Chain Management*, *18*(3), 320-342.

Efthymiou, O. K., & Ponis, S. T. (2021). Industry 4.0 technologies and their impact in contemporary logistics: A systematic literature review. *Sustainability*, *13*(21), 11643. https://doi.org/10.3390/su132111643

Mumtahina, U., Alahakoon, S., & Wolfs, P. (2024). Hyperparameter tuning of load-forecasting models using metaheuristic optimization algorithms—a systematic review. *Mathematics*, *12*(21), 3353. https://doi.org/10.3390/math12213353

Schwalbert, R. A., Amado, T., Corassa, G., Pott, L. P., Prasad, P. V. V., & Ciampitti, I. A. (2020). Satellite-based soybean yield forecast: Integrating machine learning and weather data for improving crop yield prediction in southern Brazil. *Agricultural and Forest Meteorology*, *284*, 107886. https://doi.org/10.1016/j.agrformet.2019.107886

Yunita, A., Pratama, M. I., Almuzakki, M. Z., Ramadhan, H., Akhir, E. A. P., Mansur, A. B. F., & Basori, A. H. (2025). Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models. *MethodsX*, *15*, 103462. https://doi.org/10.1016/j.mex.2025.103462